

Rapport detaille : Analyse bulk RNA-seq SigmaR1 / shSigmaR1

Remodelage transcriptionnel, programmes CAF et module SIGMAR1

Stage LLM

2026-04-06

Table des matières

1	Resume executif	2
2	Question biologique et architecture analytique	2
3	Donnees, methodes et principes de lecture	3
3.1	Jeu de donnees	3
3.2	Methodes statistiques et bio-informatiques utilisees	3
3.3	D ou viennent les signatures CAF	3
4	Controle qualite et structure globale	5
4.1	Comment lire cette couche	8
5	Vue d ensemble differentielle	9
5.1	Comment lire cette couche	11
6	Marqueurs CAF : du gene individuel au bloc interpretable	12
6.1	Ce que montrent les marqueurs	15
7	Heatmaps CAF : structure interne des blocs	17
7.1	Comment lire les heatmaps	18
8	Scores de signatures : du gene au programme	19
8.1	Ce que montrent les scores	20
9	Module centre sur SIGMAR1	21
9.1	Comment lire cette couche	23

10 GSEA Hallmark	24
10.1 Ce que montre la GSEA	25
11 Conclusion interpretable	25
12 Limites	25
13 Annexes	26
13.1 Fichiers principaux exploites dans ce rapport	26

1 Resume executif

Cette analyse compare 3 replicats CTRL a 3 replicats shSigmaR1. Le but n est pas seulement de constater la baisse de SIGMAR1, mais de comprendre dans quelle direction globale le transcriptome fibroblastique se reconfigure une fois ce gene perturbe.

Le message principal est different de celui observe avec BKCA. Ici, la composante la plus robuste ne pointe pas d abord vers un seul bloc CAF, mais vers une reorganisation transcriptionnelle importante ou les programmes proliferatifs et de cycle cellulaire prennent beaucoup de poids. Les signatures CAF restent informatives, mais elles se lisent davantage comme des tendances structurelles que comme une conversion nette vers un sous-type unique.

Metrique	Valeur
Genes collapses	14729
Echantillons	6
CTRL	3
shSigmaR1	3
DEG padj < 0.05	1546
Up en shSigmaR1	424
Down en shSigmaR1	1122
PC1 variance	40.6%
PC2 variance	27.6%
Meilleur Hallmark	HALLMARK_G2M_CHECKPOINT (NES=-2.066, FDR=9.4e-10)

2 Question biologique et architecture analytique

Le bulk RNA-seq force une discipline d interpretation. Comme il s agit d une moyenne de programmes et non d une lecture cellule par cellule, il faut articuler plusieurs niveaux d evidence avant de conclure.

On commence donc par verifier la separation globale des echantillons. Ensuite on quantifie le remodelage differentiel. Puis on descend au niveau des marqueurs et signatures CAF, car ce sont eux qui permettent de traduire le signal en termes biologiques. Enfin, on replace SIGMAR1 dans son voisinage de correlations et dans les programmes Hallmark pour voir ce qui reste le plus convaincant a l echelle systeme.

3 Donnees, methodes et principes de lecture

3.1 Jeu de donnees

Le jeu repose sur les objets `dds` et `vsd` deja prepares pendant le stage, avec 3 replicats CTRL et 3 replicats `shSigmaR1`. Apres annotation des symboles et collapse des doublons, la matrice finale contient 1.4729×10^4 genes.

Les figures d expression utilisent la matrice transformee `log2(count + 1)`. Cette echelle n est pas une quantite absolue ; c est une echelle de visualisation qui stabilise les distributions et rend les comparaisons plus lisibles.

3.2 Methodes statistiques et bio-informatiques utilisees

La couche differentielle repose sur DESeq2, avec shrinkage `apecglm` pour les `log2FoldChange`. Un `log2FoldChange` positif signifie que le gene est plus exprime en `shSigmaR1` qu en CTRL. Un `padj` faible indique que ce contraste reste solide apres correction de multiplicite.

Les panneaux gene par gene et les scores de signatures sont accompagnes d un test de Wilcoxon. Avec 3 vs 3, ce test n a pas vocation a porter tout le raisonnement a lui seul. Il sert plutot a verifier si la direction d effet visible dans les figures reste coherent echantillon par echantillon.

Les correlations autour de SIGMAR1 sont calculees avec Spearman, ce qui est plus prudent qu un modele lineaire strict dans un si petit effectif.

Pour les heatmaps, la palette suit une regle simple : quand la matrice est centree sur 0, la palette est de type `seismic`, pour garder une lecture claire des valeurs negatives et positives. Quand la matrice ne va que d un faible niveau vers un niveau eleve, la palette devient `Blues`.

3.3 D ou viennent les signatures CAF

Les signatures ne sont pas la pour forcer le jeu de donnees dans une case arbitraire. Elles servent a tester quels blocs fibroblastiques restent coherents ou, au contraire, se fragmentent apres perturbation.

— `myCAF` et `iCAF` suivent surtout le cadre Ohlund / Elyada.

- **csCAF** suit la littérature sur les fibroblastes secreteurs de complement.
- **ifCAF** suit un panel de travail assemble pour pister un axe interferon-like.
- **apCAF** suit surtout Elyada, avec le programme **MHC-II** dans le PDAC.
- Le bloc **apCAF** est aussi elargi avec **Chen X, Huang H et al. 2025, Cancer Cell, Single-cell resolution spatial analysis of antigen-presenting cancer-associated fibroblast niches.**

Comme pour **BKCA**, il faut rester critique sur **apCAF** en bulk. Le signal existe surtout via quelques genes **MHC-II** et des marqueurs etendus detectables, mais cela ne suffit pas a affirmer qu'une signature **apCAF** complete est parfaitement resolue dans ce modele.

Signature	Source	Note d'interpretation	Genes definis	Genes pre-sents en bulk
myCAF	Ohlsson et al. 2017 / Elyada et al. 2019	Contractile / myofibroblastic axis	30	25
iCAF	Ohlsson et al. 2017 / Elyada et al. 2019	Inflammatory fibroblast axis	30	27
csCAF	Complement-secreting CAFs in PDAC single-cell multiomics	Complement / secretory fibroblast axis	30	18
apCAF	Elyada et al. 2019 MHC-II anchors + Chen X, Huang H et al. 2025 Cancer Cell apCAF niche markers	Bulk readout interpreted cautiously because only a subset of apCAF genes is detectable	47	27
ifCAF	Quantified stage interferon / ifCAF-like panel	Work signature assembled to track interferon-like fibro-inflammatory signal	17	13

4 Controle qualite et structure globale




FIGURE 1 – Distributions globales des valeurs d expression bulk. Les deux panneaux servent a verifier que la transformation $\log_2(\text{count} + 1)$ rend les profils comparables sans echantillon aberrant.




FIGURE 2 – Boxplots par echantillon. L axe vertical est en $\log_2(\text{count} + 1)$. Une forme globale comparable entre echantillons est un pre-requis avant toute interpretation mecanistique.




FIGURE 3 – Densités par échantillon. Chaque courbe résume la distribution des intensités d'expression dans un échantillon.




FIGURE 4 – Heatmap de correlation echantillon-echantillon. Les correlations vont de faible a forte similarite, donc une palette Blues est ici la plus lisible.




FIGURE 5 – PCA globale sur tous les genes exprimes. Chaque point correspond a un echantillon. Les axes PC1 et PC2 resumment les directions majeures de variance.

4.1 Comment lire cette couche

Les distributions restent homogenes et la PCA separe correctement CTRL et shSigmaR1. PC1 explique 40.6% de la variance et PC2 27.6%. Ce n est pas encore une preuve mecanistique, mais c est une bonne indication que la perturbation SIGMAR1 restructure deja l espace transcriptomique global.

5 Vue d ensemble differentielle




FIGURE 6 – Volcano plot de la comparaison shSigmaR1 vs CTRL. Axe x = $\log_2 \text{FoldChange} (\text{shSigmaR1} / \text{CTRL})$. Axe y = $-\log_{10}(\text{FDR})$.




FIGURE 7 – MA-like plot. Il sert à voir si les changements différentiels sont portés par des gènes faiblement ou fortement exprimés.




FIGURE 8 – Heatmap des principaux genes differentiels, z-scoree par gene. Comme la matrice est centree sur 0, la palette `seismic` permet de lire clairement les echantillons au-dessus et au-dessous de la moyenne de chaque gene.

5.1 Comment lire cette couche

Le contraste global est reel, avec 1546 genes differentiels a $\text{padj} < 0.05$. SIGMAR1 lui-meme baisse fortement, ce qui valide le modele. Mais, biologiquement, le point important est plus large : les genes qui changent avec lui ne se resument pas a un seul module fibroblastique stable. On voit deja apparaitre un signal de reorganisation plus large, qui sera surtout clarifie plus loin par la GSEA Hallmark.

6 Marqueurs CAF : du gene individuel au bloc interpretable




FIGURE 9 – Violons des marqueurs clés. Chaque point représente un échantillon. Les annotations combinent effet différentiel et statistique Wilcoxon.




FIGURE 10 – Dotplot des marqueurs CAF. La couleur code le z-score moyen par condition et la taille la fraction de replicats au-dessus de la mediane du gene.




FIGURE 11 – Barplot de force d'expression des marqueurs CAF. Chaque barre représente le delta moyen shSigmaR1 - CTRL en $\log_2(\text{count} + 1)$.

Gene	Bloc	Moyenne CTRL	Moyenne shSigmaR1	Delta	log2FC	DE FDR	Wilcoxon p	Wilcoxon FDR	rho SIG- MAR1	rho FDR
SIGMAR1	myCAF	13.21	11.89	-	-	7.1e-16	0.0809	0.2426	1.000	0.1583
COL1A1	myCAF	18.55	19.25	0.69	0.661	3.1e-07	0.0809	0.2426	-0.600	0.4920
POSTN	myCAF	16.21	15.42	-	-	1.6e-05	0.0809	0.2426	0.829	0.3694
TAGLN	myCAF	13.80	14.18	0.37	0.303	0.0424	0.0809	0.2426	-0.657	0.4534
ACTA2	myCAF	10.74	10.94	0.20	0.162	0.3058	0.0809	0.2426	-0.600	0.4920
CCL2	iCAF	10.27	10.76	0.49	0.440	0.0413	0.0809	0.2426	-0.943	0.2714
IL6	iCAF	8.77	9.17	0.40	0.494	0.0462	0.0809	0.2426	-0.657	0.4534
CXCL12	iCAF	12.73	12.91	0.18	0.113	0.5280	0.3827	0.5977	-0.371	0.7085
CXCL8	iCAF	9.85	9.62	-	-	0.9756	0.3827	0.5977	0.543	0.5555
C3	csCAF	8.13	9.09	0.96	2.010	9.2e-12	0.0809	0.2426	-0.771	0.4534
GPX3	csCAF	11.03	11.03	0.00	0.004	0.9911	1.0000	1.0000	0.314	0.7653
CFD	csCAF	7.60	7.72	0.12	0.045	NA	0.0809	0.2426	-0.714	0.4534
CLU	apCAF	11.01	11.03	0.03	0.019	0.9288	0.3827	0.5977	-0.314	0.7653
CD74	apCAF	7.64	7.52	-	-	NA	0.1904	0.4096	0.429	0.7085
HLA-DPA1	apCAF	7.97	7.93	-	-	NA	1.0000	1.0000	0.371	0.7085
STAT2	ifCAF	12.27	12.80	0.53	0.467	0.0174	0.3827	0.5977	-0.600	0.4920

6.1 Ce que montrent les marqueurs

La lecture gene par gene reste utile, mais elle doit rester prudente vu l'effectif. Les tendances les plus lisibles suggerent un remodelage composite :

- plusieurs marqueurs contractiles ou matriciels bougent, ce qui signale un déplacement d'une composante **myCAF-like** ;
- des marqueurs inflammatoires comme IL6, CXCL8 ou CCL2 changent eux aussi, sans former un bloc parfaitement uniforme ;
- **apCAF** reste globalement discret et surtout porte par quelques ancres MHC-II ;
- certains marqueurs **csCAF-like** changent, mais la coherence du bloc reste plus modeste.

Le barplot **delta** aide ici a voir tres vite dans quel sens se deplace chaque gene moyen par signature. Il ne remplace pas les statistiques, mais il donne une lecture immediate de l'ampleur moyenne des effets.

7 Heatmaps CAF : structure interne des blocs




FIGURE 12 – Heatmap globale des signatures CAF avec annotations de bloc et de significativité. Chaque ligne est z-scoree par gene, donc la couleur indique une position relative et non un niveau absolu.




FIGURE 13 – Heatmap combinee des blocs CAF sans apCAF. Les genes sont bloques par famille biologique puis ordonnes a l interieur du bloc.

Bloc	Statut	Nombre
SigmaR1	DE_FDR<0.05	1
myCAF	DE_FDR<0.05	5
myCAF	NS	20
iCAF	DE_FDR<0.05	5
iCAF	NS	22
csCAF	DE_FDR<0.05	6
csCAF	NS	12
apCAF	DE_FDR<0.05	5
apCAF	NS	22
ifCAF	DE_FDR<0.05	1
ifCAF	NS	12

7.1 Comment lire les heatmaps

Comme dans BKCA, le z-score remet chaque gene sur une echelle comparable. Cela permet de voir si les genes d un meme bloc bougent ensemble. Dans SIGMAR1, la lecture la plus honnete est que les blocs fibroblastiques existent, mais qu aucun ne prend la forme d une bascule unique et propre. Le jeu se lit davantage comme un etat recompose, ou plusieurs dimensions CAF sont touchees en meme temps.

8 Scores de signatures : du gene au programme




FIGURE 14 – Panneaux des scores de signatures CAF. Les valeurs sont des scores moyens construits a partir des genes d une signature apres standardisation par gene.




FIGURE 15 – Dotplot des programmes CAF par condition. La couleur code le score moyen, la taille son amplitude absolue et l asterisque indique une difference Wilcoxon significative.

Signature	Moyenne CTRL	Moyenne shSigmaR1	Delta	Wilcoxon p	Wilcoxon FDR
myCAF_top30	-0.255	0.255	0.509	0.0809	0.4043
csCAF_top30	0.039	-0.039	-0.078	0.6625	1.0000
iCAF_top30	-0.037	0.037	0.074	1.0000	1.0000
apCAF_core	0.034	-0.034	-0.069	0.6625	1.0000
ifCAF_manual	0.003	-0.003	-0.006	1.0000	1.0000

8.1 Ce que montrent les scores

Le meilleur score de signature brute est myCAF_top30, avec un delta de 0.509 et une FDR de 0.4043. La lecture la plus utile n'est pas de dire qu'une signature est "validee" au sens fort, mais de voir quelle direction globale le jeu prend.

Pour apCAF_core, la lecture reste critique, avec un delta de -0.069 et une FDR de 1.0000. Comme dans BKCA, le bulk capte surtout un signal apCAF-like partiel via quelques marqueurs detectables.

9 Module centre sur SIGMAR1




FIGURE 16 – PCA restreinte au module centre sur SIGMAR1. Cette couche teste si le gene s inscrit dans un voisinage de co-variation plus large que son seul knockdown.




FIGURE 17 – Panels de correlations entre SIGMAR1 et plusieurs marqueurs cles. Chaque point correspond a un echantillon ; la statistique rapportee est une correlation de Spearman.




FIGURE 18 – Réseau de corrélations autour de SIGMAR1. Cette figure organise les proximités de corrélation les plus visibles, mais ne doit pas être lue comme un réseau causal.

9.1 Comment lire cette couche

Cette partie reste franchement exploratoire avec 6 échantillons au total. Elle est utile surtout pour organiser les hypothèses. Les associations les plus visibles sont :

- meilleure corrélation positive : EZR, avec un rho de 0.943 et une FDR de 0.2714 ;
- meilleure corrélation négative : CXADR, avec un rho de -1 et une FDR de 0.1583.

10 GSEA Hallmark




FIGURE 19 – Hallmark fgsea. L axe horizontal montre le NES (Normalized Enrichment Score). Un NES positif indique un enrichissement du cote **shSigmaR1**, un NES negatif du cote **CTRL**.

Hallmark	NES	p	FDR	Taille
HALLMARK_G2M_CHECKPOINT	-2.066	3.8e-11	9.4e-10	199
HALLMARK_E2F_TARGETS	-2.061	3e-11	9.4e-10	200
HALLMARK_MYOGENESIS	2.042	5.5e-08	9.2e-07	142
HALLMARK_P53_PATHWAY	1.921	1.8e-07	2.3e-06	183
HALLMARK_MITOTIC_SPINDLE	-1.766	2.2e-06	2.2e-05	198
HALLMARK_TNFA_SIGNALING_VIA_NFKB	1.658	4.1e-05	0.0003	184
HALLMARK_EPITHELIAL_MESENCHYMAL_TRANSITION	1.595	3e-05	0.0007	196
HALLMARK_PROTEIN_SECRETION	-1.716	0.0003	0.0016	92
HALLMARK_INFLAMMATORY_RESPONSE	1.638	0.0003	0.0016	133
HALLMARK_COAGULATION	1.793	0.0005	0.0027	96

10.1 Ce que montre la GSEA

La GSEA Hallmark est ici la couche la plus robuste du rapport. Le programme dominant est `HALLMARK_G2M_CHECKPOINT`, avec un NES de -2.066 et une FDR de $9.4e-10$. `HALLMARK_G2M_CHECKPOINT` suit la même logique, avec un NES de -2.066 et une FDR de $9.4e-10$.

Cette configuration soutient fortement l'idée que la perte de `SIGMAR1` s'accompagne d'une reorganisation dominée par des programmes prolifératifs et de cycle cellulaire. `EMT`, avec un NES de 1.595 et une FDR de 0.0007, ajoute une dimension de remodelage stromal plus large, mais le cœur du signal reste ici plus prolifératif que strictement `CAF`.

11 Conclusion interpretable

Les conclusions les plus solides sont les suivantes.

1. `shSigmaR1` sépare nettement les deux conditions au niveau transcriptomique global.
2. Le signal le plus robuste se situe du côté des programmes prolifératifs et de cycle cellulaire.
3. Les signatures `CAF` restent utiles pour structurer l'interprétation, mais elles ne montrent pas de conversion simple vers un sous-type unique.
4. Les blocs fibroblastiques sont touchés de façon composite, avec coexistence de dimensions contractiles, inflammatoires et complément-like.
5. Le bloc `apCAF` reste lisible surtout comme un axe `MHC-II/apCAF-like` partiel, à lire avec prudence.
6. Le voisinage de `SIGMAR1` paraît structuré, mais la couche corrélations/réseau reste exploratoire.

En pratique, la formulation la plus juste est que la **perturbation de SigmaR1 s'accompagne d'un remodelage bulk important, dominé par des programmes prolifératifs, sur lequel se superposent des variations fibroblastiques plus hétérogènes.**

12 Limites

- L'effectif est très petit (3 vs 3).
- Il s'agit d'un bulk, donc d'une moyenne de programmes et non d'une lecture cellule par cellule.
- Les signatures `CAF` restent interprétatives et non définitives.
- La partie corrélations autour de `SIGMAR1` doit rester exploratoire.

13 Annexes

13.1 Fichiers principaux exploites dans ce rapport

- outputs/SIGMAR1_shSIGMAR1_bulk_rebuilt_v2/figures/
- outputs/SIGMAR1_shSIGMAR1_bulk_rebuilt_v2/tables/
- outputs/SIGMAR1_shSIGMAR1_bulk_rebuilt_v2/rds/SIGMAR1_shSIGMAR1_bulk_rebuilt_v2_bundle.

Last updated : 2026-04-06